Relatório Técnico

Arquitetura de Dados e Pipeline de Business Intelligence

Nome: Mauro Baptista

Cargo: Data Analyst & Business Intelligence Specialist

Contacto Directo: maurobaptista18@gmail.com

Público-Alvo: Data Analysts, Data Engineers, Stakeholders Técnicos.
Objetivo: Documentar a infraestrutura tecnológica, os processos de Extração, Transformação e Carga (ETL) e a modelação semântica no Power BI, garantindo reprodutibilidade do projeto.

1. Stack Tecnológico e Arquitetura de Dados

O projeto adotou uma arquitetura robusta de três camadas:

1. **Camada de Ingestão e Limpeza:** Python 3.13 (Pandas, SQLAlchemy, Psycopg2).
2. **Camada de Armazenamento e Processamento (Data Warehouse):** PostgreSQL 16.
3. **Camada Semântica e Visualização:** Microsoft Power BI (Motor DAX / VertiPaq).

2. Fase de Ingestão e Integração (Python to PostgreSQL)

A base de dados de origem (ficheiro CSV) continha os registos granulares de milhares de videojogos. Para garantir a governança dos dados, a inserção foi feita via script, abandonando importações manuais suscetíveis a erro humano.

Utilizou-se o SQLAlchemy como ORM (Object-Relational Mapper) juntamente com o driver nativo psycopg2-binary para garantir comunicação direta com a porta 5432 do PostgreSQL.

Script de Integração de Dados (Jupyter Notebook):

```
Python

# Instalação das dependências no kernel ativo
%pip install psycopg psycopg2-binary SQLAlchemy pandas

import pandas as pd
from sqlalchemy import create_engine
```

```
# 1. Leitura e Validação dos Dados Brutos
df = pd.read_csv('vgsales.csv')
# (Tratamento de nulos e normalização de datatypes realizados via Pandas)

# 2. Configuração do Motor de Conexão Segura
# Formato: postgresql+driver://user:password@host:port/database
motor                                                                    =
create_engine('postgresql+psycopg2://postgresxxxxxt:5432/postgres')

# 3. Ingestão para Base de Dados Relacional
df.to_sql(
    name='vendas_videojogos',
    con=motor,
    if_exists='replace',  # Permite reprocessamento (Idempotência)
    index=False           # Omissão de indexação desnecessária do Pandas
)
print("Pipeline de ingestão concluído com sucesso.")
```

3. Fase de Processamento e Exploração (SQL Analytics)

Com os dados carregados no esquema `public`, executou-se a Análise Exploratória de Dados (EDA) diretamente no motor de base de dados utilizando ANSI SQL. Esta fase validou as regras de negócio antes da construção do dashboard.

Nota de Engenharia: Como o Pandas exportou a estrutura preservando a capitalização original (Case-Sensitive), as queries PostgreSQL exigiram *double quotes* (`" "`) nos identificadores das colunas.

Query Estratégica 1: Risco de Concentração Geográfica (> 80% na América do Norte)
Para evitar falhas operacionais (`Division by Zero`), foi implementada lógica condicional no `WHERE`.

SQL

```
SQL

SELECT
    "Game",
    "North_America",
    "Global",
```

```
    ROUND(("North_America" / "Global") * 100, 2) AS percentagem_na
FROM vendas_videojogos
WHERE "Global" > 0
  AND ("North_America" / "Global") > 0.80
ORDER BY percentagem_na DESC;
```

Query Estratégica 2: Identificação de Mega-Hits por Editora (>10 Milhões)

Utilizou-se a ordem de execução do SQL para filtrar anomalias positivas (outliers) antes da agregação (`GROUP BY`). Adicionalmente, foi usada a função `STRING_AGG` para concatenar os nomes dos jogos num formato legível.

SQL

```
SQL
SELECT
    "Publisher",
    COUNT("Game") AS mega_hits,
    STRING_AGG("Game", ', ') AS lista_de_jogos
FROM vendas_videojogos
WHERE "Global" > 10
GROUP BY "Publisher"
ORDER BY mega_hits DESC;
```

Query Estratégica 3: Eficiência por Género

SQL

```
SQL
SELECT
    "Genre",
    ROUND(AVG("Global"), 2) AS receita_media_por_titulo,
    SUM("Global") AS receita_total_acumulada
FROM vendas_videojogos
GROUP BY "Genre"
ORDER BY receita_media_por_titulo DESC;
```

4. Fase de Modelação Semântica e Business Intelligence (Power BI)

A transição do SQL para o Power BI exigiu uma mudança de paradigma técnico. Para garantir a interatividade total do Dashboard (*cross-filtering* dinâmico), tomou-se a decisão de engenharia de **não importar agregações SQL pré-calculadas**.

4.1. Configuração de Conectividade

- A base de dados foi conetada via conector nativo PostgreSQL.
- **Modo de Armazenamento:** Import Mode. A tabela granular (vendas_videojogos) foi carregada integralmente para a memória RAM (motor VertiPaq) para garantir latência zero nas interações de utilizador, dispensando o uso de DirectQuery.

4.2. Modelação DAX e Lógica Condicional

Para replicar a métrica de "Risco de Concentração Geográfica" de forma dinâmica no painel, sem depender da view relacional, foi desenvolvida a seguinte Coluna Calculada em DAX utilizando a função DIVIDE (que previne nativamente divisões por zero, retornando *blank* ou o valor alternativo estipulado):

Fragmento do código

```
None

% Dependencia NA =
DIVIDE(
   'vendas_videojogos'[North_America],
   'vendas_videojogos'[Global],
   0
)
```

4.3. Desenvolvimento de UI/UX e Interatividade

O dashboard foi projetado para responder às necessidades da direção sem necessidade de intervenção técnica:

- **Top N Filtering Dinâmico:** Implementação de visuais de Barras Horizontais (Editoras vs. Vendas Globais) restritos via painel de filtros ao critério "N Superior = 5 (Por Valor: Vendas Globais)".
- **Slicers (Filtros Interativos):** Criação de segmentadores de dados contextuais. Ao selecionar uma editora específica (ex: *Electronic Arts*), todos os gráficos da tela (Série Temporal de Lançamentos, Pizza de Distribuição de Géneros) recalculam-se instantaneamente, respondendo à questão: *Qual é a dependência de género e o ritmo produtivo desta empresa em específico?*

- **Matriz de Dados:** Incorporação da métrica calculada de `% Dependência NA` num formato tabular cruzado para deteção rápida de anomalias (identificando visualmente títulos de alto risco global).

5. Conclusão e Impacto do Projeto

O desenvolvimento deste pipeline End-to-End validou a transição de um modelo de tomada de decisão empírico para um modelo científico. Ao integrar o Pandas para automação de ETL, o PostgreSQL como armazém centralizado e o Power BI como interface analítica, estabelecemos as fundações de uma infraestrutura *Data-Driven*. A capacidade de auditar milhões em vendas de forma instantânea e interativa erradica o "achismo" da mesa de decisões, garantindo precisão milimétrica na alocação de orçamentos de desenvolvimento futuros.